

Importação de Dados Retangulares - Excel

Isabela Diniz Cia

Conjunto de Dados

O conjunto de dados em questão é o conjunto de índices de desenvolvimento mundial, disponibilizado pelo Banco Mundial através do link <http://datatopics.worldbank.org/world-development-indicators/>.

Expectativas

Ao fim deste laboratório, você deverá ser capaz de:

- Importar dados de planilhas específicas de arquivos em formato Excel;
- Trabalhar com variáveis cujos nomes fogem do padrão usual de programação (por exemplo, variáveis com espaços brancos em seus nomes);
- Selecionar variáveis do interesse;
- Verificar se os dados estão no formato tidy e transformá-los para tal formato;
- Optar apropriadamente entre filtering joins e mutating joins;
- Produzir visualizações de dados de séries temporais;

Atividades

1. Carregue os pacotes `readxl` e `tidyverse`.

```
library(readxl)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
```

```
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

2. Crie uma variável chamada `fname` que contenha o caminho para o arquivo `WDIEXCEL.xlsx`, disponível no seu diretório de dados. Confirme que o R identifica a existência do arquivo utilizando o comando `file.exists`

```
fname <- "wdiexcel.xlsx"
file.exists(fname)
```

```
[1] TRUE
```

3. Leia a planilha “Country” e armazene no objeto `countries`.

```
excel_sheets(fname)
```

```
[1] "Data"          "Country"        "Series"          "Country-Series"
[5] "Series-Time"   "FootNote"
```

```
countries <- read_excel(fname, sheet = 'Country')
head(countries)
```

```
# A tibble: 6 x 30
  `Country Code` `Short Name` `Table Name` `Long Name`          `2-alpha code`
  <chr>          <chr>      <chr>      <chr>          <chr>
1 ABW           Aruba       Aruba       Aruba          AW
2 AFG           Afghanistan Afghanistan Islamic State of Afgh~ AF
3 AGO           Angola      Angola      People's Republic of ~ AO
4 ALB           Albania    Albania    Republic of Albania  AL
5 AND           Andorra    Andorra    Principality of Andor~ AD
6 ARB           Arab World Arab World Arab World      1A
# i 25 more variables: `Currency Unit` <chr>, `Special Notes` <chr>,
#   Region <chr>, `Income Group` <chr>, `WB-2 code` <chr>,
#   `National accounts base year` <chr>,
#   `National accounts reference year` <chr>, `SNA price valuation` <chr>,
#   `Lending category` <chr>, `Other groups` <chr>,
#   `System of National Accounts` <chr>, `Alternative conversion factor` <chr>,
#   `PPP survey year` <chr>, `Balance of Payments Manual in use` <chr>, ...
```

4. Mantenha apenas os registros de 5 países (Brasil e outros 4 de sua escolha).

```
countries <- countries %>%
  filter(`Country Code` %in% c("BRA", "USA", "JPN", "CHN", "IND"))
head(countries)
```

```
# A tibble: 5 x 30
  `Country Code` `Short Name` `Table Name` `Long Name`      `2-alpha code`
  <chr>          <chr>        <chr>      <chr>          <chr>
1 BRA           Brazil      Brazil      Federative Republic~ BR
2 CHN           China       China       People's Republic o~ CN
3 IND           India       India       Republic of India    IN
4 JPN           Japan       Japan       Japan                JP
5 USA           United States United States United States of Am~ US
# i 25 more variables: `Currency Unit` <chr>, `Special Notes` <chr>,
#   Region <chr>, `Income Group` <chr>, `WB-2 code` <chr>,
#   `National accounts base year` <chr>,
#   `National accounts reference year` <chr>, `SNA price valuation` <chr>,
#   `Lending category` <chr>, `Other groups` <chr>,
#   `System of National Accounts` <chr>, `Alternative conversion factor` <chr>,
#   `PPP survey year` <chr>, `Balance of Payments Manual in use` <chr>, ...
```

5. Leia a planilha “Data” e armazene no objeto WDI.

```
# Transformei o arquivo em .csv, para conseguir fazer a leitura fracionada dos dados

processa_WDI <- function(input, pos) {
  input %>%
    filter(`Country Code` %in% countries$`Country Code`) %>%
    select(
      `Country Code`,
      `Indicator Code`,
      `1960`:`2018`
    )
}

WDI <- read_delim_chunked(
  "Data.csv",
  delim = ";",
  callback = DataFrameCallback$new(processa_WDI),
  chunk_size = 100000,
  show_col_types = FALSE
```

```
)
```

```
head(WDI)
```

```
# A tibble: 6 x 61
  `Country Code` `Indicator Code` `1960` `1961` `1962` `1963` `1964` `1965`
  <chr>          <chr>          <chr> <chr> <chr> <chr> <chr> <chr>
1 BRA          PA.NUS.PPP.05      <NA> <NA> <NA> <NA> <NA> <NA>
2 BRA          PA.NUS.PRVT.PP.05 <NA> <NA> <NA> <NA> <NA> <NA>
3 BRA          EG.CFT.ACCS.ZS   <NA> <NA> <NA> <NA> <NA> <NA>
4 BRA          EG.ELC.ACCS.ZS   <NA> <NA> <NA> <NA> <NA> <NA>
5 BRA          EG.ELC.ACCS.RU.ZS <NA> <NA> <NA> <NA> <NA> <NA>
6 BRA          EG.ELC.ACCS.UR.ZS <NA> <NA> <NA> <NA> <NA> <NA>
# i 53 more variables: `1966` <chr>, `1967` <chr>, `1968` <chr>, `1969` <chr>,
#   `1970` <chr>, `1971` <chr>, `1972` <chr>, `1973` <chr>, `1974` <chr>,
#   `1975` <chr>, `1976` <chr>, `1977` <chr>, `1978` <chr>, `1979` <chr>,
#   `1980` <chr>, `1981` <chr>, `1982` <chr>, `1983` <chr>, `1984` <chr>,
#   `1985` <chr>, `1986` <chr>, `1987` <chr>, `1988` <chr>, `1989` <chr>,
#   `1990` <chr>, `1991` <chr>, `1992` <chr>, `1993` <chr>, `1994` <chr>,
#   `1995` <chr>, `1996` <chr>, `1997` <chr>, `1998` <chr>, `1999` <chr>, ...
```

6. Selecione apenas as colunas:

- Country Code
- Indicator Code
- E todos os anos de 1960-2018

```
WDI <- WDI %>%
  select(
    `Country Code`,
    `Indicator Code`,
    `1960`:`2018`
  )
```

```
head(WDI)
```

```
# A tibble: 6 x 61
  `Country Code` `Indicator Code` `1960` `1961` `1962` `1963` `1964` `1965`
  <chr>          <chr>          <chr> <chr> <chr> <chr> <chr> <chr>
1 BRA          PA.NUS.PPP.05      <NA> <NA> <NA> <NA> <NA> <NA>
2 BRA          PA.NUS.PRVT.PP.05 <NA> <NA> <NA> <NA> <NA> <NA>
3 BRA          EG.CFT.ACCS.ZS   <NA> <NA> <NA> <NA> <NA> <NA>
```

```

4 BRA          EG.ELC.ACCS.ZS      <NA>    <NA>    <NA>    <NA>    <NA>    <NA>
5 BRA          EG.ELC.ACCS.RU.ZS    <NA>    <NA>    <NA>    <NA>    <NA>    <NA>
6 BRA          EG.ELC.ACCS.UR.ZS    <NA>    <NA>    <NA>    <NA>    <NA>    <NA>
# i 53 more variables: `1966` <chr>, `1967` <chr>, `1968` <chr>, `1969` <chr>,
#   `1970` <chr>, `1971` <chr>, `1972` <chr>, `1973` <chr>, `1974` <chr>,
#   `1975` <chr>, `1976` <chr>, `1977` <chr>, `1978` <chr>, `1979` <chr>,
#   `1980` <chr>, `1981` <chr>, `1982` <chr>, `1983` <chr>, `1984` <chr>,
#   `1985` <chr>, `1986` <chr>, `1987` <chr>, `1988` <chr>, `1989` <chr>,
#   `1990` <chr>, `1991` <chr>, `1992` <chr>, `1993` <chr>, `1994` <chr>,
#   `1995` <chr>, `1996` <chr>, `1997` <chr>, `1998` <chr>, `1999` <chr>, ...

```

7. Confirme se os dados em WDI estão em formato `tidy`. Se não estiverem, transforme-os para tal formato. Faça de forma que exista uma coluna referente ao ano chamada `YEAR`.

```
str(WDI)
```

```

tibble [7,995 x 61] (S3: tbl_df/tbl/data.frame)
 $ Country Code  : chr [1:7995] "BRA" "BRA" "BRA" "BRA" ...
 $ Indicator Code: chr [1:7995] "PA.NUS.PPP.05" "PA.NUS.PRVT.PP.05" "EG.CFT.ACCS.ZS" "EG.ELC
 $ 1960          : chr [1:7995] NA NA NA NA ...
 $ 1961          : chr [1:7995] NA NA NA NA ...
 $ 1962          : chr [1:7995] NA NA NA NA ...
 $ 1963          : chr [1:7995] NA NA NA NA ...
 $ 1964          : chr [1:7995] NA NA NA NA ...
 $ 1965          : chr [1:7995] NA NA NA NA ...
 $ 1966          : chr [1:7995] NA NA NA NA ...
 $ 1967          : chr [1:7995] NA NA NA NA ...
 $ 1968          : chr [1:7995] NA NA NA NA ...
 $ 1969          : chr [1:7995] NA NA NA NA ...
 $ 1970          : chr [1:7995] NA NA NA NA ...
 $ 1971          : chr [1:7995] NA NA NA NA ...
 $ 1972          : chr [1:7995] NA NA NA NA ...
 $ 1973          : chr [1:7995] NA NA NA NA ...
 $ 1974          : chr [1:7995] NA NA NA NA ...
 $ 1975          : chr [1:7995] NA NA NA NA ...
 $ 1976          : chr [1:7995] NA NA NA NA ...
 $ 1977          : chr [1:7995] NA NA NA NA ...
 $ 1978          : chr [1:7995] NA NA NA NA ...
 $ 1979          : chr [1:7995] NA NA NA NA ...
 $ 1980          : chr [1:7995] NA NA NA NA ...
 $ 1981          : chr [1:7995] NA NA NA NA ...
 $ 1982          : chr [1:7995] NA NA NA NA ...

```

```

$ 1983      : chr [1:7995] NA NA NA NA ...
$ 1984      : chr [1:7995] NA NA NA NA ...
$ 1985      : chr [1:7995] NA NA NA NA ...
$ 1986      : chr [1:7995] NA NA NA NA ...
$ 1987      : chr [1:7995] NA NA NA NA ...
$ 1988      : chr [1:7995] NA NA NA NA ...
$ 1989      : chr [1:7995] NA NA NA NA ...
$ 1990      : chr [1:7995] NA NA NA "87,475116" ...
$ 1991      : chr [1:7995] NA NA NA "90,1516571" ...
$ 1992      : chr [1:7995] NA NA NA "88,803833" ...
$ 1993      : chr [1:7995] NA NA NA "89,999927" ...
$ 1994      : chr [1:7995] NA NA NA "91,54168701" ...
$ 1995      : chr [1:7995] NA NA NA "91,728598" ...
$ 1996      : chr [1:7995] NA NA NA "92,867095" ...
$ 1997      : chr [1:7995] NA NA NA "93,354139" ...
$ 1998      : chr [1:7995] NA NA NA "94,193812" ...
$ 1999      : chr [1:7995] NA NA NA "94,76296" ...
$ 2000      : chr [1:7995] NA NA "86,91" "94,39329529" ...
$ 2001      : chr [1:7995] NA NA "87,89" "96,016528" ...
$ 2002      : chr [1:7995] NA NA "88,8" "96,652996" ...
$ 2003      : chr [1:7995] NA NA "89,55" "96,980098" ...
$ 2004      : chr [1:7995] NA NA "90,3" "96,765107" ...
$ 2005      : chr [1:7995] "1,356743033" "1,571318409" "91,04" "97,093513" ...
$ 2006      : chr [1:7995] NA NA "91,67" "97,594314" ...
$ 2007      : chr [1:7995] NA NA "92,17" "98,125382" ...
$ 2008      : chr [1:7995] NA NA "92,73" "98,526625" ...
$ 2009      : chr [1:7995] NA NA "93,27" "98,856938" ...
$ 2010      : chr [1:7995] NA NA "93,66" "98,8462677" ...
$ 2011      : chr [1:7995] NA NA "94,07" "99,328691" ...
$ 2012      : chr [1:7995] NA NA "94,48" "99,519494" ...
$ 2013      : chr [1:7995] NA NA "94,77" "99,575151" ...
$ 2014      : chr [1:7995] NA NA "95,1" "99,650247" ...
$ 2015      : chr [1:7995] NA NA "95,38" "99,710902" ...
$ 2016      : chr [1:7995] NA NA "95,59" "99,7" ...
$ 2017      : chr [1:7995] NA NA NA "100" ...
$ 2018      : chr [1:7995] NA NA NA NA ...

```

Nao esta em formato tidy, pois os anos sao observacoes a variavel deveria ser 'YEAR'

```

WDI <- WDI %>%
  pivot_longer(
    cols = `1960`:`2018`,

```

```

    names_to = "YEAR",
    values_to = "VALUE"
  )

head(WDI)

```

```

# A tibble: 6 x 4
  `Country Code` `Indicator Code` YEAR  VALUE
  <chr>          <chr>          <chr> <chr>
1 BRA           PA.NUS.PPP.05    1960  <NA>
2 BRA           PA.NUS.PPP.05    1961  <NA>
3 BRA           PA.NUS.PPP.05    1962  <NA>
4 BRA           PA.NUS.PPP.05    1963  <NA>
5 BRA           PA.NUS.PPP.05    1964  <NA>
6 BRA           PA.NUS.PPP.05    1965  <NA>

```

8. Confirme se a coluna referente ao ano está em formato inteiro.

```
str(WDI)
```

```

tibble [471,705 x 4] (S3: tbl_df/tbl/data.frame)
 $ Country Code  : chr [1:471705] "BRA" "BRA" "BRA" "BRA" ...
 $ Indicator Code: chr [1:471705] "PA.NUS.PPP.05" "PA.NUS.PPP.05" "PA.NUS.PPP.05" "PA.NUS.PPP.05" ...
 $ YEAR          : chr [1:471705] "1960" "1961" "1962" "1963" ...
 $ VALUE         : chr [1:471705] NA NA NA NA ...

```

```

WDI <- WDI %>%
  mutate(YEAR = as.integer(YEAR))

str(WDI)

```

```

tibble [471,705 x 4] (S3: tbl_df/tbl/data.frame)
 $ Country Code  : chr [1:471705] "BRA" "BRA" "BRA" "BRA" ...
 $ Indicator Code: chr [1:471705] "PA.NUS.PPP.05" "PA.NUS.PPP.05" "PA.NUS.PPP.05" "PA.NUS.PPP.05" ...
 $ YEAR          : int [1:471705] 1960 1961 1962 1963 1964 1965 1966 1967 1968 1969 ...
 $ VALUE         : chr [1:471705] NA NA NA NA ...

```

9. Para o objeto WDI, mantenha apenas os registros dos países listados em countries. Selecione as colunas:

- Country Code

- Short Name
- YEAR
- SP.DYN.CBRT.IN

```
WDI <- WDI %>%
  filter(`Indicator Code` == "SP.DYN.CBRT.IN") %>%
  left_join(
    countries %>%
      select(`Country Code`, `Short Name`),
    by = "Country Code"
  ) %>%
  rename(
    `SP.DYN.CBRT.IN` = VALUE
  ) %>%
  select(
    `Country Code`,
    `Short Name`,
    YEAR,
    `SP.DYN.CBRT.IN`
  )

head(WDI)
```

```
# A tibble: 6 x 4
  `Country Code` `Short Name`  YEAR SP.DYN.CBRT.IN
  <chr>          <chr>      <int> <chr>
1 BRA           Brazil      1960 42,336
2 BRA           Brazil      1961 42,029
3 BRA           Brazil      1962 41,611
4 BRA           Brazil      1963 41,064
5 BRA           Brazil      1964 40,392
6 BRA           Brazil      1965 39,61
```

10. Ordene o objeto de forma que, para cada país, as informações estejam ordenadas por ano.

```
WDI <- WDI %>%
  arrange(
    `Country Code`,
    YEAR
  )

head(WDI)
```

```
# A tibble: 6 x 4
  `Country Code` `Short Name` YEAR SP.DYN.CBRT.IN
  <chr>          <chr>      <int> <chr>
1 BRA           Brazil      1960 42,336
2 BRA           Brazil      1961 42,029
3 BRA           Brazil      1962 41,611
4 BRA           Brazil      1963 41,064
5 BRA           Brazil      1964 40,392
6 BRA           Brazil      1965 39,61
```

```
WDI <- WDI %>%
  mutate(
    `SP.DYN.CBRT.IN` = parse_number(
      `SP.DYN.CBRT.IN`,
      locale = locale(decimal_mark = ",")
    )
  )

str(WDI)
```

```
tibble [295 x 4] (S3: tbl_df/tbl/data.frame)
 $ Country Code   : chr [1:295] "BRA" "BRA" "BRA" "BRA" ...
 $ Short Name     : chr [1:295] "Brazil" "Brazil" "Brazil" "Brazil" ...
 $ YEAR           : int [1:295] 1960 1961 1962 1963 1964 1965 1966 1967 1968 1969 ...
 $ SP.DYN.CBRT.IN: num [1:295] 42.3 42 41.6 41.1 40.4 ...
```

11. Construa um gráfico de linhas, usando o pacote `ggplot2`, que tenha no eixo X a variável `YEAR`, no eixo Y a variável `SP.DYN.CBRT.IN` e que cada linha corresponda a um país diferente.

```
library(ggplot2)


ggplot(
  WDI,
  aes(
    x = YEAR,
    y = `SP.DYN.CBRT.IN`,
    color = `Short Name`
  )
) +
  geom_line() +
  labs(
```

```

    title = "Taxa de natalidade ao longo do tempo",
    x = "Ano",
    y = "Taxa de natalidade",
    color = "País"
  ) +
  theme_minimal() +
  theme(
    panel.grid.major.x = element_blank(),
    panel.grid.minor.x = element_blank(),
    panel.grid.major.y = element_line(
      colour = "gray",
      linewidth = 0.5),
    panel.grid.minor.y = element_line(
      colour = "gray",
      linewidth = 0.2)
  )

```

Warning: Removed 5 rows containing missing values or values outside the scale range (`geom\_line()`).



Horário de conclusão

```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-09-09 18:31:52 -03"
```