

SQLite - Parte II

Isabela Diniz Cia

SQLite

O **SQLite** é uma biblioteca embutida em um processo único que é autônomo, não necessita de servidor e exige zero de configuração. O código é de domínio público e seu uso é gratuito em qualquer tipo de utilização. Trata-se de um sistema SQL completo, capaz de utilizar múltiplas tabelas, índices, gatilhos e visões. Ele funciona, virtualmente, em qualquer plataforma (incluindo móveis) e pesa cerca de 600KB.

Objetivos

Ao fim deste laboratório, você deverá ser capaz de:

- Conectar-se a um banco de dados do tipo **SQLite** utilizando o **R** como interface;
- Explorar quais são as tabelas disponíveis no referido banco de dados;
- Identificar quais são as colunas de uma dada tabela existente no banco de dados;
- Realizar pesquisas simples;
- Extrair registros do banco de dados e armazená-las em objetos do **R**;
- Realizar algumas pesquisas complexas, utilizando **WHERE**, **INNER JOIN**.
- Criar novas tabelas no banco de dados.

Fonte do problema:

Estes dados são de uma iniciativa de publicidade de desempenho de alunos e professores nas Universidades Americanas. A UW-Madison disponibilizou os seus dados online (no Office of the Registrar: <https://registrar.wisc.edu/>), e alguém trouxe os dados para uma competição no Kaggle (<https://www.kaggle.com/Madgrades/uw-madison-courses>). Nesta atividades, examinaremos disciplinas oferecidas no assunto de Estatística pela referida Universidade. O esquema do banco de dados é apresentado na figura abaixo.

Observações

- Esta tarefa não deve ser realizada no site `jupyter.ime.unicamp.br`;
- Você deve realizar o download dos dados para o computador que estiver utilizando e, então, iniciar a atividade;
- Recomenda-se a utilização dos seguintes pacotes: `RSQLite`;
- Toda a atividade deve ser realizada utilizando-se apenas de `SQLite` (i.e., não utilize `dbplyr`);

Atividade

1. Baixe o arquivo `uwmadison.sqlite3`. Conecte-se a ele usando o pacote `RSQLite`, armazenando a conexão em uma variável `conn`.

```
path <- getwd() # path <- "/cloud/project"
fname <- file.path(path, "database.sqlite3")

library(RSQLite)

conn <- dbConnect(SQLite(), fname)
conn
```

```
<SQLiteConnection>
  Path: /cloud/project/database.sqlite3
  Extensions: TRUE
```

```
dbListTables(conn)
```

```
[1] "course_offerings"  "courses"           "grade_distributions"
[4] "instructors"       "rooms"              "schedules"
[7] "sections"          "subject_memberships" "subjects"
[10] "teachings"
```

2. Quem são e quantos são os professores que lecionaram disciplinas cujo tópico era estatística (subjects.abbreviation='STAT');

Nomes dos professores

```
teacher_stat_db = dbGetQuery(conn, '
  SELECT DISTINCT instructors.name
  FROM subjects
  INNER JOIN subject_memberships
    ON subjects.code = subject_memberships.subject_code
  INNER JOIN course_offerings
    ON subject_memberships.course_offering_uuid = course_offerings.uuid
  INNER JOIN sections
    ON course_offerings.uuid = sections.course_offering_uuid
  INNER JOIN teachings
    ON sections.uuid = teachings.section_uuid
  INNER JOIN instructors
    ON teachings.instructor_id = instructors.id
  WHERE subjects.abbreviation="STAT"
  ')

head(teacher_stat_db)
```

```
      name
1  MINJING TAO
2  DONALD PORTER
3    SHENG WANG
4  KUNLING HUANG
5    DONG XIA
6 JENNIFER NGUYEN
```

Quantidade de professores

```
nrow(teacher_stat_db)
```

```
[1] 377
```

3. O GPA americano é definido numa escala de 0 a 4, em que A = 4, AB = 3.5, B = 3, BC = 2.5, C = 2, D = 1 e F = 0. Determinando a nota média de cada oferecimento pela ponderação da quantidade de alunos em cada extrato com os valores numéricos de cada conceito, indique (no que se referente a disciplinas no assunto de estatística):

- Quem é o professor mais difícil?

```
prof_dificil = dbGetQuery(conn, '
SELECT
  instructors.name AS professor,
  AVG((a_count*4 + ab_count*3.5 + b_count*3 + bc_count*2.5
      + c_count*2 + d_count*1 + f_count*0) /
      (a_count + ab_count + b_count + bc_count + c_count
      + d_count + f_count)) AS gpa_medio
FROM grade_distributions
INNER JOIN sections
  ON grade_distributions.course_offering_uuid = sections.course_offering_uuid
INNER JOIN teachings
  ON sections.uuid = teachings.section_uuid
INNER JOIN instructors
  ON teachings.instructor_id = instructors.id
INNER JOIN course_offerings
  ON grade_distributions.course_offering_uuid = course_offerings.uuid
INNER JOIN subject_memberships
  ON course_offerings.uuid = subject_memberships.course_offering_uuid
INNER JOIN subjects
  ON subject_memberships.subject_code = subjects.code
WHERE subjects.abbreviation = "STAT"
  AND (a_count + ab_count + b_count + bc_count + c_count
      + d_count + f_count) > 0
GROUP BY instructors.name
ORDER BY gpa_medio ASC
LIMIT 1
')

prof_dificil
```

	professor	gpa_medio
1	JAMES D KUELBS	2.59875

- Quem é o professor mais fácil?

```
prof_facil = dbGetQuery(conn, '
SELECT
  instructors.name AS professor,
  AVG((a_count*4 + ab_count*3.5 + b_count*3 + bc_count*2.5 + c_count*2
    + d_count*1 + f_count*0) /
    (a_count + ab_count + b_count + bc_count + c_count
    + d_count + f_count)) AS gpa_medio
FROM grade_distributions
INNER JOIN sections
  ON grade_distributions.course_offering_uuid = sections.course_offering_uuid
INNER JOIN teachings
  ON sections.uuid = teachings.section_uuid
INNER JOIN instructors
  ON teachings.instructor_id = instructors.id
INNER JOIN course_offerings
  ON grade_distributions.course_offering_uuid = course_offerings.uuid
INNER JOIN subject_memberships
  ON course_offerings.uuid = subject_memberships.course_offering_uuid
INNER JOIN subjects
  ON subject_memberships.subject_code = subjects.code
WHERE subjects.abbreviation = "STAT"
  AND (a_count + ab_count + b_count + bc_count + c_count
    + d_count + f_count) > 0
GROUP BY instructors.name
ORDER BY gpa_medio DESC
LIMIT 1
')

prof_facil
```

	professor	gpa_medio
1	YAJUAN SI	4

-
- Qual é a disciplina mais difícil?

```

disc_dificil = dbGetQuery(conn, '
SELECT
  courses.name AS disciplina,
  AVG((a_count*4 + ab_count*3.5 + b_count*3 + bc_count*2.5 + c_count*2
    + d_count*1 + f_count*0) /
    (a_count + ab_count + b_count + bc_count + c_count
    + d_count + f_count)) AS gpa_medio
FROM grade_distributions
INNER JOIN sections
  ON grade_distributions.course_offering_uuid = sections.course_offering_uuid
INNER JOIN course_offerings
  ON grade_distributions.course_offering_uuid = course_offerings.uuid
INNER JOIN subject_memberships
  ON course_offerings.uuid = subject_memberships.course_offering_uuid
INNER JOIN subjects
  ON subject_memberships.subject_code = subjects.code
INNER JOIN courses
  ON course_offerings.course_uuid = courses.uuid
WHERE subjects.abbreviation = "STAT"
  AND (a_count + ab_count + b_count + bc_count + c_count
    + d_count + f_count) > 0
GROUP BY courses.name
ORDER BY gpa_medio ASC
LIMIT 1
')

disc_dificil

```

	disciplina	gpa_medio
1	Introduction to the Theory of Probability	2.901418

-
- Qual é a disciplina mais fácil?

```

disc_facil = dbGetQuery(conn, '
SELECT
  courses.name AS disciplina,
  AVG((a_count*4 + ab_count*3.5 + b_count*3 + bc_count*2.5 + c_count*2
    + d_count*1 + f_count*0) /
    (a_count + ab_count + b_count + bc_count + c_count

```

```

        + d_count + f_count)) AS gpa_medio
FROM grade_distributions
INNER JOIN sections
    ON grade_distributions.course_offering_uuid = sections.course_offering_uuid
INNER JOIN course_offerings
    ON grade_distributions.course_offering_uuid = course_offerings.uuid
INNER JOIN subject_memberships
    ON course_offerings.uuid = subject_memberships.course_offering_uuid
INNER JOIN subjects
    ON subject_memberships.subject_code = subjects.code
INNER JOIN courses
    ON course_offerings.course_uuid = courses.uuid
WHERE subjects.abbreviation = "STAT"
    AND (a_count + ab_count + b_count + bc_count + c_count
        + d_count + f_count) > 0
GROUP BY courses.name
ORDER BY gpa_medio DESC
LIMIT 1
')
disc_facil

```

	disciplina	gpa_medio
1	Sample Survey Theory and Method	4

4. Desconecte do banco de dados.

```
dbDisconnect(conn)
```

Horário de conclusão

```

Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()

```

[1] "2026-09-23 18:38:26 -03"