

Lab 01 - Isabela Diniz Cia

AUTHOR
Isabela Diniz Cia

Laboratório 01

Manipulação de Dados no Formato Tidy

- Carregue o pacote `tidyverse`

```
library('tidyverse')
```

Warning: pacote 'tidyverse' foi compilado no R versão 4.5.3

```
— Attaching core tidyverse packages — tidyverse 2.0.0 —
✓ dplyr      1.1.4    ✓ readr      2.1.5
✓ forcats    1.0.0    ✓ stringr   1.5.1
✓ ggplot2    3.5.2    ✓ tibble     3.2.1
✓ lubridate  1.9.4    ✓ tidyr      1.3.1
✓ purrr      1.0.4
— Conflicts ————— tidyverse_conflicts() —
X dplyr::filter() masks stats::filter()
X dplyr::lag()    masks stats::lag()
! Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become err
```

- Apresente os bancos de dados `table1`, `table2`, `table3`, `table4a` e `table4b`, distribuídos juntamente com o pacote `tidyverse`. Para cada banco de dados, descreva textualmente se ele está no formato tidy e justifique cada uma de suas respostas.

```
tidyr::table1
```

```
# A tibble: 6 × 4
  country   year cases population
<chr>     <dbl> <dbl>     <dbl>
1 Afghanistan 1999    745   19987071
2 Afghanistan 2000   2666  20595360
3 Brazil       1999  37737  172006362
4 Brazil       2000  80488  174504898
5 China        1999 212258 1272915272
6 China        2000 213766 1280428583
```

```
tidyr::table2
```

```
# A tibble: 12 × 4
  country   year type      count
<chr>     <dbl> <chr>     <dbl>
1 Afghanistan 1999 cases        745
2 Afghanistan 1999 population 19987071
3 Afghanistan 2000 cases        2666
4 Afghanistan 2000 population 20595360
5 Brazil       1999 cases       37737
6 Brazil       1999 population 172006362
7 Brazil       2000 cases       80488
8 Brazil       2000 population 174504898
9 China        1999 cases      212258
10 China       1999 population 1272915272
11 China       2000 cases      213766
12 China       2000 population 1280428583
```

```
tidyr::table3
```

```
# A tibble: 6 × 3
  country   year rate
<chr>     <dbl> <chr>
1 Afghanistan 1999 745/19987071
2 Afghanistan 2000 2666/20595360
3 Brazil       1999 37737/172006362
4 Brazil       2000 80488/174504898
5 China        1999 212258/1272915272
6 China        2000 213766/1280428583
```

```
tidyr::table4a
```

```
# A tibble: 3 × 3
  country   1999`  `2000`
<chr>     <dbl>  <dbl>
1 Afghanistan    745    2666
2 Brazil       37737  80488
3 China       212258 213766
```

```
tidyr::table4b
```

```
# A tibble: 3 × 3
  country   `1999`  `2000`
<chr>     <dbl>    <dbl>
1 Afghanistan 19987071  20595360
2 Brazil     172006362 174504898
3 China     1272915272 1280428583
```

- Resposta:** O formato *tidy* possui como característica organizar a tabela de modo que cada coluna corresponda a uma variável, cada linha represente uma observação e cada célula contenha apenas um único valor.

Ao analisar os conjuntos de dados `table1`, `table2`, `table3`, `table4a` e `table4b`, observamos que a `table1` está no formato *tidy*, pois cada variável contempla uma coluna, resultando em uma tabela no formato longo. A `table2`, por sua vez, apresenta na coluna `type` dois valores distintos (`cases` e `population`), que correspondem a duas variáveis diferentes e deveriam estar separadas. Na `table3`, a coluna `rate` não está no formato *tidy* porque cada célula armazena duas informações simultaneamente. Por fim, nas tabelas `table4a` e `table4b`, os anos de 1999 e 2000 figuram como colunas, quando na verdade deveriam ser agrupados para formar uma nova coluna referente à variável `ano`.

- Utilizando comandos do pacote `dplyr`, determine a taxa de ocorrência de tuberculose para cada 10.000 pessoas. Armazene o resultado em um objeto chamado `taxas`.

```
library(dplyr)
```

```
taxas <- tidyr::table1 %>%
  mutate(taxa = (cases / population) * 10000)
```

```
taxas
```

```
# A tibble: 6 × 5
  country   year cases population taxa
<chr>     <dbl> <dbl>     <dbl> <dbl>
1 Afghanistan 1999    745   19987071 0.373
2 Afghanistan 2000   2666  20595360 1.29
3 Brazil       1999  37737  172006362 2.19
4 Brazil       2000  80488  174504898 4.61
5 China        1999 212258 1272915272 1.67
6 China        2000 213766 1280428583 1.67
```

- Apresente, utilizando comandos do pacote `dplyr`, o número de casos de tuberculose por ano.

```
casos_por_ano <- tidyr::table1 %>%
  group_by(year) %>%
  summarise(total_casos = sum(cases))
```

```
casos_por_ano
```

```
# A tibble: 2 × 2
  year total_casos
<dbl>     <dbl>
1 1999    250740
2 2000    296920
```

- Apresente, utilizando comandos do pacote `dplyr`, o número de casos de tuberculose identificados em cada país.

```
casos_por_pais <- tidyr::table1 %>%
  group_by(country) %>%
  summarise(total_pais = sum(cases))
```

```
casos_por_pais
```

```
# A tibble: 3 × 2
  country total_pais
<chr>     <dbl>
1 Afghanistan    3411
2 Brazil       118225
3 China       426024
```

- Utilizando comandos do pacote `dplyr`, apresente uma tabela que descreva a mudança no número de casos, em cada país, ao longo dos anos de 1999 e 2000.

```
library(tidyr)
```

```
mudanca_casos <- table1 %>%
  select(country, year, cases) %>%
  pivot_wider(names_from = year, values_from = cases, names_prefix = "casos_") %>%
  mutate(diferenca = casos_2000 - casos_1999)
```


```
mudanca_casos
```

```
# A tibble: 3 × 4
  country casos_1999 casos_2000 diferenca
<chr>     <dbl>     <dbl>     <dbl>
1 Afghanistan    745        2666        1921
2 Brazil       37737       80488       42751
3 China       212258      213766       1508
```

- Apresente um gráfico de linhas, preparado via `ggplot2`, apresentando a mudança na taxa de casos (por 10.000 habitantes) estratificado por país.

```
library(ggplot2)
```

```
ggplot(taxas, aes(x = year, y = taxa, color = country)) +
  geom_line() +
  geom_point() +
  labs(title = 'Taxa de Tuberculose por Pais',
       x = 'Ano', y = 'Taxa (por 10.000 hab.)')
```



- Calcule a taxa para as tabelas `table2` e `table4a+table4b`. Para isso, você precisará executar 4 passos:

- Extrair o número de casos de tuberculose por país, por ano;
- Extrair o tamanho da população correspondente, por ano;
- Dividir o número de casos pelo tamanho da população e multiplicar o resultado por 10.000;
- Armazenar o resultado numa variável apropriada;

Taxa `table2`

```
# Realizando o procedimento na table2

# Extrair o número de casos de tuberculose por país, por ano
casos_table2 <- table2 %>%
  filter(type == 'cases') %>%
  rename(cases = count)
```

```
# Extrair o tamanho da população correspondente, por ano
populacao_table2 <- table2 %>%
  filter(type == 'population') %>%
  rename(population = count)
```

```
populacao_table2
```

```
# A tibble: 6 × 4
  country   year type      population
<chr>     <dbl> <chr>     <dbl>
1 Afghanistan 1999 population 19987071
2 Afghanistan 2000 population 20595360
3 Brazil       1999 population 172006362
4 Brazil       2000 population 174504898
5 China        1999 population 1272915272
6 China        2000 population 1280428583
```

```
# Dividir o número de casos pelo tamanho da população e multiplicar o resultado por 10.000
taxa_table2 <- table2 %>%
  pivot_wider(names_from = type, values_from = count) %>%
  mutate(taxa = (cases / population) * 10000)
```

```
#Armazenar o resultado numa variável apropriada
taxa_table2
```

```
# A tibble: 6 × 5
  country   year cases population taxa
<chr>     <dbl> <dbl>     <dbl> <dbl>
1 Afghanistan 1999    745   19987071 0.373
2 Afghanistan 2000   2666  20595360 1.29
3 Brazil       1999  37737  172006362 2.19
4 Brazil       2000  80488  174504898 4.61
5 China        1999 212258 1272915272 1.67
6 China        2000 213766 1280428583 1.67
```

Taxa `table4a` + `table4b`

```
# Realizando o procedimento na table4a+table4b

# Extrair o número de casos de tuberculose por país, por ano
casos_table4 <- table4a %>%
  pivot_longer(cols = -country, names_to = "year", values_to = "cases")
```

```
# Extrair o tamanho da população correspondente, por ano
populacao_table4 <- table4b %>%
  pivot_longer(cols = -country, names_to = "year", values_to = "population")
```

```
# Dividir o número de casos pelo tamanho da população e multiplicar o resultado por 10.000
# Armazenar o resultado numa variável apropriada
taxa_table4 <- casos_table4 %>%
  left_join(populacao_table4, by = c("country", "year")) %>%
  mutate(taxa = (cases / population) * 10000)
```

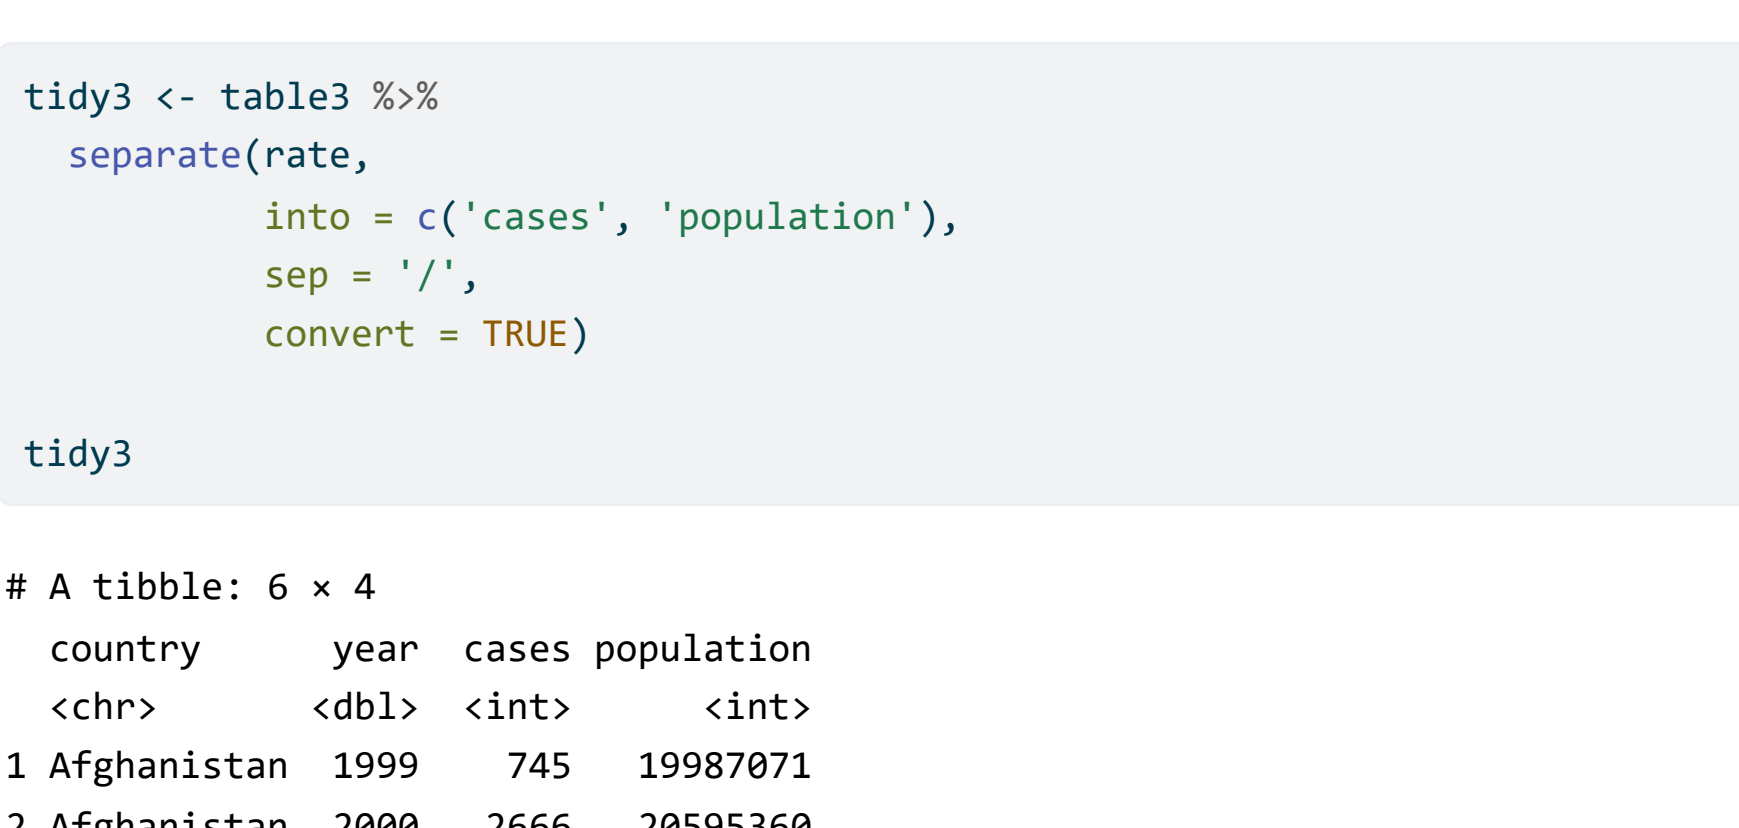
```
taxa_table4
```

```
# A tibble: 6 × 5
  country   year cases population taxa
<chr>     <chr> <dbl>     <dbl> <dbl>
1 Afghanistan 1999    745   19987071 0.373
2 Afghanistan 2000   2666  20595360 1.29
3 Brazil       1999  37737  172006362 2.19
4 Brazil       2000  80488  174504898 4.61
5 China        1999 212258 1272915272 1.67
6 China        2000 213766 1280428583 1.67
```

- Refaça o gráfico da questão 7 para os dados apresentados em `table2`.

```
library(ggplot2)
```

```
taxa_table2 %>%
  ggplot(aes(x = year, y = taxa, color = country)) +
  geom_line() +
  geom_point() +
  labs(
    title = "Mudança na Taxa de Tuberculose por País (1999-2000)",
    x = "Ano",
    y = "Taxa (casos por 10.000 habitantes)"))
```



- Utilizando o comando `pivot_longer`, transforme `table4a` em um objeto no formato tidy. Armazene o resultado num objeto chamado `tidy4a`.

```
tidy4a <- table4a %>%
  pivot_longer(cols = -country, names_to = "year", values_to = "cases")
```

```
tidy4a
```

```
# A tibble: 6 × 3
  country   year cases
<chr>     <chr> <dbl>
1 Afghanistan 1999    745
2 Afghanistan 2000   2666
3 Brazil       1999  37737
4 Brazil       2000  80488
5 China        1999 212258
6 China        2000 213766
```

- Refaça o item 10 para o objeto `table4b`. Armazene o resultado num objeto chamado `tidy4b`.

```
tidy4b <- table4b %>%
  pivot_longer(cols = -country, names_to = "year", values_to = "population")
```

```
tidy4b
```

```
# A tibble: 6 × 3
  country   year population
<chr>     <chr>     <dbl>
1 Afghanistan 1999    19987071
2 Afghanistan 2000    20595360
3 Brazil       1999    172006362
4 Brazil       2000    174504898
5 China        1999    1272915272
6 China        2000    1280428583
```

- Combine os objetos `tidy4a` e `tidy4b` em um único objeto, utilizando o comando `left_join`. Apresente uma explicação textual sobre o que faz o referido comando.

```
table4 <- tidy4a %>%
  left_join(tidy4b, by = c("country", "year"))
```

```
table4
```

```
# A tibble: 6 × 4
  country   year cases population
<chr>     <dbl> <dbl>     <dbl>
1 Afghanistan 1999    745   19987071
2 Afghanistan 2000   2666  20595360
3 Brazil       1999  37737  172006362
4 Brazil       2000  80488  174504898
5 China        1999 212258 1272915272
6 China        2000 213766 1280428583
```

- Use o comando `pivot_wider` para transformar o objeto `table2` em um objeto com formato tidy.

```
tidy2 <- table2 %>%
  pivot_wider(names_from = type, values_from = count)
```

```
tidy2
```

```
# A tibble: 6 × 4
  country   year cases population
<chr>     <dbl> <dbl>     <dbl>
1 Afghanistan 1999    745   19987071
2 Afghanistan 2000   2666  20595360
3 Brazil       1999  37737  172006362
4 Brazil       2000  80488  174504898
5 China        1999 212258 1272915272
6 China        2000 213766 1280428583
```

- Observe que a coluna `rate` do objeto `table3` é um texto mostrando a fração que formaria a taxa de casos de tuberculose. Transforme o objeto `table3` em um objeto com formato tidy separando a coluna 3 em duas outras colunas: `cases` e `population`, utilizando o comando `separate`. Utilize o argumento `convert` para transformar o resultado em um objeto numérico.

```
tidy3 <- table3 %>%
  separate(rate,
           into = c('cases', 'population'),
           sep = '/',
           convert = TRUE)
```

```
tidy3
```

```
# A tibble: 6 × 4
  country   year cases population
<chr>     <dbl> <dbl>     <dbl>
1 Afghanistan 1999    745   19987071
2 Afghanistan 2000   2666  20595360
3 Brazil       1999  37737  172006362
4 Brazil       2000  80488  174504898
5 China        1999 212258 1272915272
6 China        2000 213766 1280428583
```